性能优化 V2：实测性能对照

Qidian (Martin) Xing | 78,682条公司年度记录、8,971家公司；截至2014可用于拟合66,400条。2015-2018共12,282条，已被多轮查看。

Recipe	Cutoff	Input	Sel	Seeds	Yr AP	Pool AP	ROC	R@5	Min	Source
V0 base	2011	18/01	Y	1	NA	0.145	0.835	NA	NA	Archive
V0 L1	2011	13/01	N	1	NA	0.295	0.858	NA	NA	Archive
V1 RF	2012	S1	Y	1	0.215	0.206	0.862	0.460	0.428	V1
V1 DL	2012	S1	Y	1	0.110	0.105	0.815	0.294	0.602	V1
P2 old L1	2014	L1/01	Pre	5	0.262	0.259	0.862	0.524	2.798	Mean score
P2 lag XGB	2014	Lag3/V1	Pre	5	0.303	0.296	0.853	0.513	0.605	Mean score
P2 Cat raw	2014	RAW/V1	Pre	5	0.279	0.271	0.852	0.488	0.583	Mean score
P2 V1 RF	2014	S1/V1	Pre	5	0.286	0.286	0.891	0.504	1.399	Mean score
P2 V1 DL	2014	S1/V1	Pre	5	0.228	0.214	0.874	0.462	1.057	Mean score
P2 overall	2014	LEGACY33/native/half-life3	Y	5	0.313	0.325	0.904	0.540	0.331	Mean score
P2 DL	2014	RAW17/01/half-life3	Y	5	0.393	0.392	0.912	0.621	5.487	Mean score
P2 blend	2014	annual ranks	Y	5	0.373	0.383	0.922	0.620	NA	Rank blend
Rank old L1	2014	annual ranks	Pre	5	0.262	0.254	0.861	0.524	NA	Rank reference
Rank lag XGB	2014	annual ranks	Pre	5	0.303	0.300	0.853	0.513	NA	Rank reference
Rank Cat raw	2014	annual ranks	Pre	5	0.279	0.270	0.851	0.488	NA	Rank reference
Rank V1 RF	2014	annual ranks	Pre	5	0.286	0.281	0.892	0.504	NA	Rank reference

开发期选定的固定年度rank融合，历史年度 AP=0.373；冻结的同截止年强基准中，点估计最高的是 baseline_v1_lags_xgb（0.303），差值 +0.070。年度AP点估计超过四条强基准。四组配对年度 AP 区间下界均为正，但仍只是固定模型与当前样本下的条件证据。

Yr AP 为历史四年AP等权均值；Pool AP与ROC为合并统计；R@5为逐年Top5%召回均值。Min为拟合计时分钟；seed mean先平均预测再评分。Sel表示各版本/家族内选定；Archive为旧档案，不是新实验。年度ROC guardrail另见selection_trace，完整身份见baseline_bridge.csv。

2. 旧版为何曾经更好：证据与边界

单年控制配方	2012 AP	秒
xgb_raw_keepbest	0.239	0.654
legacy192_s1	0.206	22.082
legacy192_raw18	0.249	59.504
xgb_LAGS_RAW3	0.333	6.668
legacy192_inner_l1	0.214	170.366
xgb_RATIO_CORE	0.291	6.149
xgb_RAW17	0.285	1.123
legacy192_epochrefit	0.256	62.872
legacy192_raw17	0.325	196.214
legacy192_clip005	0.314	157.399
legacy192_quantile	0.243	26.896
legacy64_raw18	0.259	18.227
legacy192_keepbest	0.263	37.591
legacy192_unweighted	0.364	117.674
legacy192_ros_steps	0.392	141.263
legacy192_ros_epochs	0.417	234.856

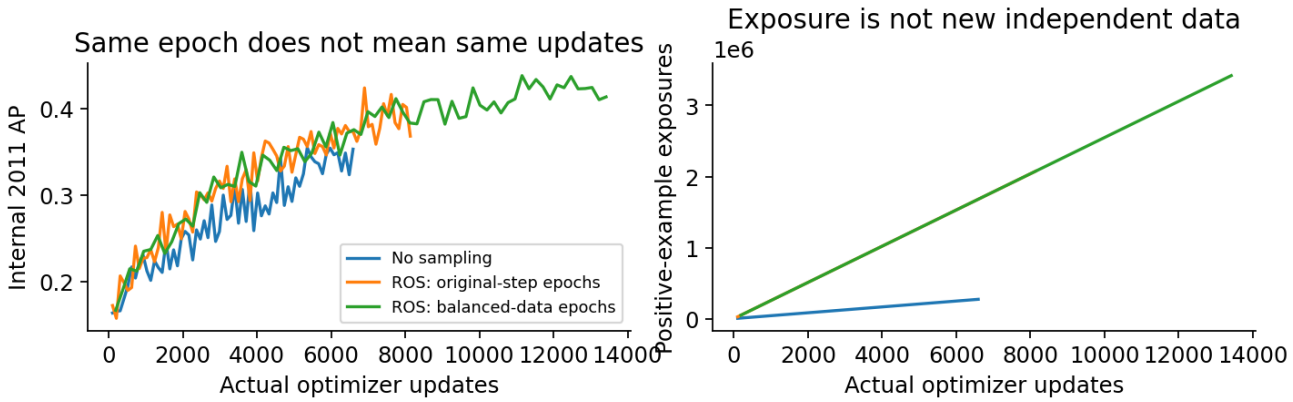
可确认：旧 Residual 为 192×4、约30万参数；V1 选定网络为64×2、36,801参数、ROS、18个最终epoch。输入、截尾、损失权重、停止与重拟合角色也不同。旧AP函数与sklearn在真实保存分数及ties样例上相同，不能把差距归咎于指标定义。

这些控制实验固定2012评分年与seed42，只支持该环境下的机制诊断。大容量并非自动更优，单个高分也不能证明普遍欠拟合或过拟合。固定旧13列含原2012-2014选择信息，只用于档案角色重训；正式开发每折重新执行L1。原包中epoch31的checkpoint与桥接表epoch23不同，身份分别保留。

2012单年对照中，RAW18同配置将容量192×4改为64×2，AP从0.249到0.259，并不支持‘更大必更好’。仅去掉原始重复列为0.325，仅取消完整类别加权为0.364。这些验证了局部机制的敏感性，尚不能解释整段历史的新旧差距。

旧角色实跑：固定13列原训练循环重训的 pooled AP=0.225；原包epoch31 checkpoint重载为0.140。前者未复现档案0.295，后者不是档案epoch23。已纠正这两条档案复算的缓存行序错误，并对全部47个冻结流水线逐行重载核验；没有新增训练或改变选择。

3. 采样、数值处理与真实训练预算



横轴是实际optimizer更新次数。右图是正类曝光次数，复制或插值不会产生新的独立公司。

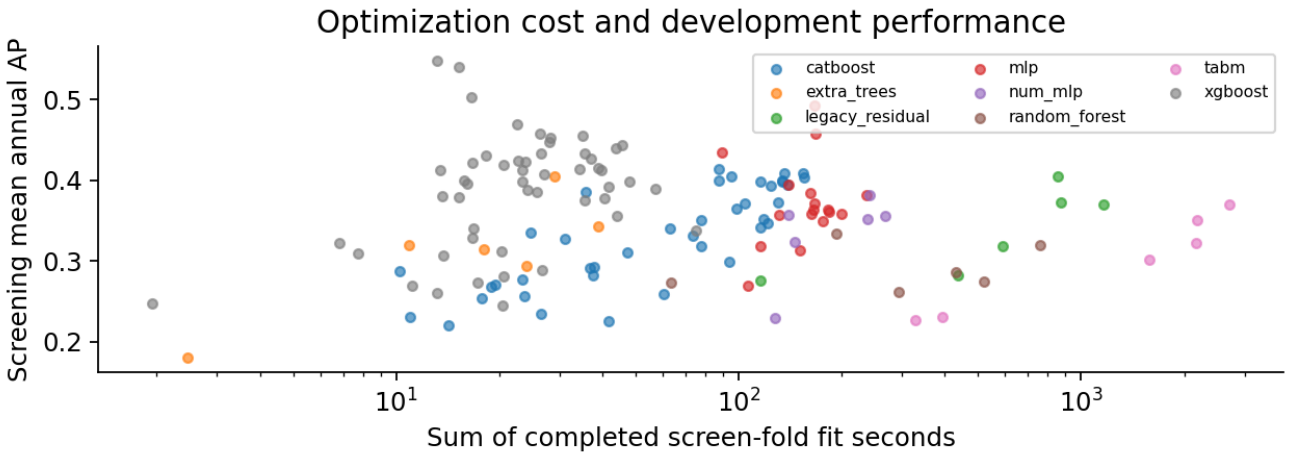
固定更新控制	更新次数	正类曝光	训练BCE
bridge_equal2000_none__seed42__year2012	2000	80778	0.246
bridge_equal2000_smote__seed42__year2012	2000	509988	0.498
bridge_equal2000_ros__seed42__year2012	2000	509988	0.480

另做无采样、ROS、SMOTE各2,000次更新控制。NN比较旧1/99%截尾、0.5/99.5%、稳健尺度与训练内normal quantile；二元mask不做quantile。仅在训练角色移除常量和重复mask，保留全部记录。数值embedding使用官方模块，TabM逐head求BCE后平均，推断平均sigmoid概率。

V2迁移的V1 ROS epoch重拟合曾遗漏采样后行数，已将那条trial标记无效、保留证据并重跑；这是本轮迁移修复，不能拿来解释原V1下降。主搜索固定step分支不受影响。

4. 搜索不是模型名单：覆盖与选择

家族	完成配置	失败	剪枝
catboost	36	0	0
xgboost	36	0	0
random_forest	6	0	0
extra_trees	6	0	0
legacy_residual	6	0	0
mlp	6	0	0
num_mlp	6	0	0
tabm	6	0	0
official_ft	0	0	0
xgb_rank	0	0	0



每个点是一个真实三年初筛配置，未把fold或seed计作不同方法。

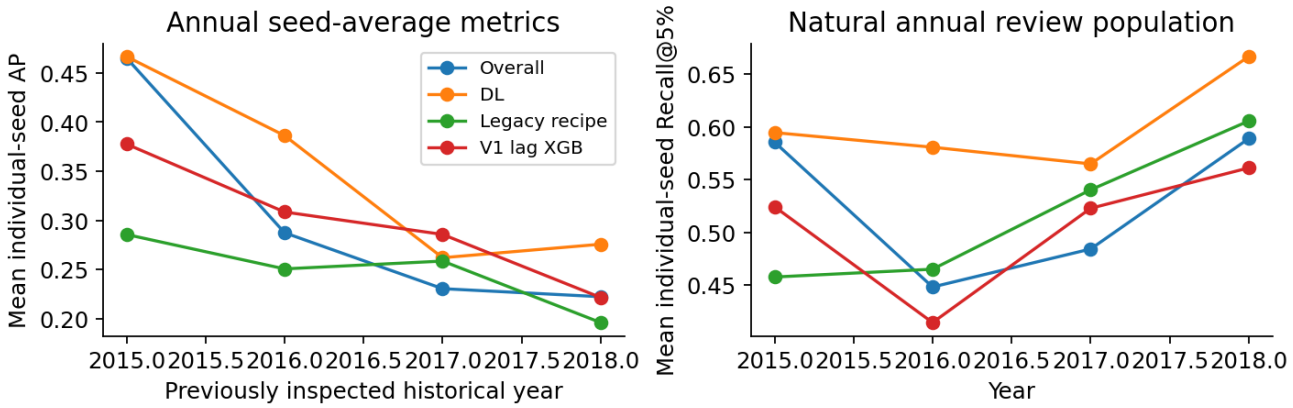
初筛2009/2011/2013；入围补齐2009-2013五年，再按42/2026/31415三seed×年度平均选择。每家最多2个、总共最多8个；AP差0.005以内按近期年度AP、Top5召回和成本取舍。强旧配方、LAGS、CatBoost与原RF基准均可入围，不强迫新模型或S1胜出。

5. 是否超过强旧配方，而非弱Logistic

开发期选定的固定年度rank融合，历史年度 AP=0.373；冻结的同截止年强基准中，点估计最高的是 baseline_v1_lags_xgb（0.303），差值 +0.070。年度AP点估计超过四条强基准。四组配对年度 AP 区间下界均为正，但仍只是固定模型与当前样本下的条件证据。

描述性对照：整体单配方的原始 pooled AP=0.325，旧L1档案=0.295（差+0.029）。两者截止年、选择和seed角色不同，不能把这个档案差值归因于算法；它与同截止年的年度AP比较分开。

同协议强基准	年度AP差下界	上界	有效抽样
baseline_legacy_strong_inner_l1	0.039	0.186	2000
baseline_v1_lags_xgb	0.002	0.144	2000
baseline_v1_raw_catboost	0.029	0.166	2000
baseline_v1_selected_rf	0.032	0.148	2000



这里是各seed指标的均值，与“先平均预测再算AP”是不同统计量。

旧档案L1的pooled AP=.295332来自训练截至2011、验证2012-2014选epoch的单seed配置，且不是原验证ROC规则选中的代表。P2所有强基准与新模型均按同一截止2014重训。不能把P1/P2截止年差异、年度rank归一化或seed融合收益全部叫作新算法提升。

本轮究竟改了什么：用新结果回答

overall 选定配方：{"depth": 8, "family": "xgboost", "features": "LEGACY33", "half_life": 3, "iterations": 1500, "learning_rate": 0.07016184471619624, "preprocess": "native", "sampling": "none", "weight_alpha": 0}；五年×三seed AP=0.529。

DL 选定配方：{"depth": 2, "family": "mlp", "features": "RAW17", "half_life": 3, "learning_rate": 0.001, "preprocess": "std01", "sampling": "none", "schedule": "fixed", "weight_alpha": 0, "width": 128}；五年×三seed AP=0.500。

主干	输入/尺度	无embedding AP	PLE AP	变化
num_mlp	RAW/01	0.382	0.357	-0.025
num_mlp	Log/QT	0.324	0.356	0.033
tabm	RAW/01	0.323	0.351	0.029
tabm	Log/QT	0.231	0.301	0.070

2014 一次确认	AP	ROC	R@5
Overall	0.572	0.906	0.592
DL	0.527	0.905	0.556
legacy_strong_inner_l1	0.311	0.823	0.430
v1_lags_xgb	0.311	0.822	0.401
v1_selected_rf	0.422	0.877	0.493

神经网络单配方：选定DL年度 AP=0.393；同截止年V1 DL=0.228（差+0.165），旧强L1配方=0.262（差+0.131）。这些是先平均五seed预测再评分的历史点估计，稳定性与区间另列。

PLE差异仅是同主干、单seed、三个开发年的成对结果。最终配方同时改变多项时，只能归因于整条流水线；2014不会触发重选。

固定选定配方和seed42，仅改变训练截止规则：截至2012的年度AP=0.242，截至2014=0.305。这是用过2013选择信息的P2迁移，不能冒称严格P1；滚动窗配方同时按相同窗长规则移动起点。

计算预算：首个8小时窗口到期时仅有部分开发结果；用户随后明确授权续跑，另登记最多8小时。两次时钟、原部分交付和已完成fold均保留；本次最终结果使用额外授权计算，不能写成首轮8小时内全部完成。实际计时与fit调用见experiment_summary和fit_accounting。

相同树配方的三年开发输入对照：RAW17=0.400, RATIO_CORE=0.322, LAGS_RAW3=0.392。这是seed42的条件对照，完整配置和差值见matched_input_controls.csv。

开发单因素对照：xgboost half_life=3: 0.458 -> 0.548; mlp half_life=3: 0.382 -> 0.493。半衰期3年使早3年的记录相对权重减半，再归一化均值为1；评分群体不变。改进机制的经济解释仍需事件日期验证，不能把历史增量全部归因于单项。

6. 稳定性、公司压力与是否值得

配方	seeds	均值	最小	最大
baseline_legacy_strong_inner_l1	5	0.248	0.225	0.300
baseline_logistic	1	0.169	0.169	0.169
baseline_v1_lags_xgb	5	0.298	0.294	0.304
baseline_v1_raw_catboost	5	0.274	0.262	0.284
baseline_v1_selected_dl_corrected_step	5	0.181	0.161	0.211
baseline_v1_selected_rf	5	0.281	0.273	0.295
refine_r3_15_a028aa7a	5	0.301	0.293	0.316
refine_r3_21_bbf84fb1	5	0.348	0.327	0.388

公司聚类配对bootstrap默认2,000次，整家公司抽样，并保留同一次抽样配对。区间条件于固定模型与当前历史样本，不包含完整HPO、校准、宏观冲击或未来数据版本不确定性。采用年度rank融合时，区间固定原年度参考群体。

公司压力测试排除留组公司的所有拟合标签，但超参数已在更广公司上选择，因此准确名称是post-selection stress。自然未见公司按2014截止定义，failed公司极少；单类年份指标保留NA。计算成本、失败/无效trial与未启动计划均保留，不用参数量增加代替性能证据。

历史期DL代表年度AP=0.393，高于开发期冻结融合的0.373；融合未在该期改善DL的AP。保留预先选择，不按历史最高行替换主结果。

Role	Groups	AP mean	Min	Max	R@5
DL	3	0.138	0.077	0.206	0.413
ML	3	0.143	0.097	0.206	0.360

自然未见公司按共同的截至2014可用群体定义：468家公司，其中failed公司5家。实际滚动窗拟合公司集合在最终拟合前另行登记。下表是三组排除公司后的pooled AP均值与范围，不是置信区间；参数已在更广公司上选择。

7. 如何核查与面试表达

先读baseline_bridge、selection_trace和paired_company_intervals，再看全部trials、development_by_year和costs。模型、预处理、列序、训练步数、配置和预测保存在本地artifacts。verify从保存预测独立重算并随机重载一个树和一个NN。

面试应说：在Codex辅助下完成有预算的真实优化，区分旧档案、同协议重训与新选择；能解释哪些变化有控制证据，哪些仍是猜测。个人贡献与原团队成果分别致谢，尚不声称本人手工重写每行或已独立复核。简历草稿仅保留本地。

标签在公司内恒定，缺少真实事件日、财报发布日期与固定horizon。校准分数不是已验证的一年期PD；时间划分、公司hash和本轮优化都不能恢复未接触过的外部测试。原团队致谢和AI说明见父目录及本轮说明。

技术来源：官方TabM、rtdl-num-embeddings、rtdl-revisiting-models、CatBoost、XGBoost和Optuna。版本与合同检查见configs/runtime_versions.json及software_contracts.json。