性能优化 V2：预算到期的部分结果

Qidian (Martin) Xing | 本轮未完成性能升级。下表只有已核验的开发期结果，没有新的最终历史成绩或模型工件。

Recipe/version	Fit to	Input/scale	Sel	Seeds	Year AP	Pool AP	ROC	R@5	Min	Identity
V1/P2 RF	08/10/12	V1_S1/v1	N/A	1	0.418	0.411	0.871	0.397	0.753	DEV 09/11/13
V0/P2 inner L1	08/10/12	INNER_L1/std01	N/A	1	0.225	0.209	0.785	0.260	3.195	DEV 09/11/13
V1/P2 lag XGB	08/10/12	V1_LAGS/v1	N/A	1	0.232	0.220	0.786	0.270	0.311	DEV 09/11/13
V1/P2 Cat raw	08/10/12	V1_S0/v1	N/A	1	0.207	0.088	0.660	0.252	0.296	DEV 09/11/13
V1/P2 DL	08/10/12	V1_S1/v1	N/A	1	0.252	0.250	0.821	0.279	0.763	DEV 09/11/13
V2 MLP raw	08/10/12	RAW17/std01	N/A	1	0.382	0.357	0.830	0.380	3.948	DEV 09/11/13
V2 old Res raw	08/10/12	RAW17/std01	N/A	1	0.370	0.347	0.827	0.358	19.336	DEV 09/11/13
V2 catboost	08/10/12	SLOG_RATIO/native	N/A	1	0.318	0.309	0.828	0.319	1.295	DEV 09/11/13
V2 xgboost	08/10/12	LAGS_RAW3/native	N/A	1	0.329	0.320	0.836	0.326	0.277	DEV 09/11/13
V2 extra_trees	08/10/12	RATIO_CORE/none	N/A	1	0.343	0.337	0.845	0.344	0.650	DEV 09/11/13
V2 tabm	08/10/12	RAW17/std01	N/A	1	0.323	0.303	0.822	0.328	36.234	DEV 09/11/13

共同开发口径下，固定V1/P2 RF仍最高：年度AP=0.418；普通Raw MLP=0.382。均为seed42、三个评分年。不能据此填写“历史表现提升”，也不能与旧档案0.295的历史pooled AP直接比较。

评分年为2009/2011/2013，对应训练截至2008/2010/2012。Pool AP与ROC合并不同折训练模型的评分；R@5为逐年召回均值。所有新配方的最终选择仍为Pending；截至2014的最终共同口径对照尚未完成。

2. 旧版为什么曾经更好：能确认什么

旧档案身份	历史AP	历史ROC
base_scaled	0.145	0.835
lasso_selected_scaled	0.295	0.858

2012单年控制配方	AP	秒
xgb_raw_keepbest	0.239	0.654
legacy192_s1	0.206	22.082
legacy192_raw18	0.249	59.504
xgb_LAGS_RAW3	0.333	6.668
legacy192_inner_l1	0.214	170.366
xgb_RATIO_CORE	0.291	6.149
xgb_RAW17	0.285	1.123
legacy192_epochrefit	0.256	62.872
legacy192_raw17	0.325	196.214
legacy192_clip005	0.314	157.399
legacy192_quantile	0.243	26.896
legacy64_raw18	0.259	18.227
legacy192_keepbest	0.263	37.591
legacy192_unweighted	0.364	117.674
legacy192_ros_steps	0.392	141.263
legacy192_ros_epochs	0.417	234.856

旧Residual为192×4，18维输入302,209参数；V1所选网络36,801参数、ROS、18个最终epoch。输入、截尾、权重、早停和重拟合角色都变了。旧AP与sklearn在真实保存评分和ties样例上一致，不能把差距归咎于指标定义。

控制实验中，无权重、截尾和采样改变了单年结果；较大容量并非总更好。这里只验证了固定2012和seed42下的变化，不能证明它们导致了2015-2018的差距。旧L1的0.295不是按旧验证ROC选中的代表，也不是性能下界；原包epoch31 checkpoint与档案epoch23不同。

3. 方法、取舍与未验证的假设

P1基础模型截至2012，2013校准，2014阈值；P2开发期选配置、最终允许拟合至2014。P2若用了2013选择信息，不能再把2013叫独立校准年。本轮没有完成新的P1/P2最终模型，不能借角色切换宣称算法进步。

相同epoch并不代表相同更新次数：ROS/SMOTE改变样本数。已做各2,000更新的无采样/ROS/SMOTE控制并记录正类曝光；复制和插值不产生新的独立公司。曲线同时保存训练/内部停止AP、BCE、梯度和饱和比例，不能只凭epoch少诊断欠拟合。

RAW17、精简比率、三年日历历史等已有真实开发结果。训练内截尾、标准化与quantile不接触评分标签，mask另行处理。无embedding的数值MLP与普通MLP得到完全相同的AP，因此不能算两种独立新方法。官方PLE与TabM合同测试通过，不等于完成了它们的性能实验。

TabM只有一个完整无embedding配置，AP约0.323；尚未完成充分调参或PLE成对性能训练。FT、ranking与权重/滚动窗等覆盖不足，不能下架构优劣结论。所声明的TabM20-epoch控制最终没有启动，不能当作实验结果。

4. 实际覆盖、成本与是否值得

家族	完整配置	目标	缺口
catboost	7	36	29
xgboost	7	36	29
random_forest	2	12	10
extra_trees	2	12	10
legacy_residual	1	18	17
mlp	1	18	17
num_mlp	1	14	13
tabm	1	14	13
official_ft	0	8	8
xgb_rank	0	6	6

完整三年初筛22个trial，去掉功能重复后21个有效不同配方；完整局部修正3个，单年桥接19个，记账拟合调用267次。fold、seed和TabM head都没有当作新方法。

真实目标远未达到，不能称“充分调优”。总UTC窗口出现长间隔，但现有证据没有确认原因；单调拟合计时与总wall-clock分开报告。最后拟合启动在原截止前，截止后没有补跑。结项材料是在窗口结束后整理的。

本轮没有建立超过旧强配方的历史证据，也没有完成五seed稳定性和公司泛化。不能用架构名称、参数量或单年高分来替代这些证据。更多计算是否值得，须在下一次获授权的预算内完成真实共同口径比较后再判断。

5. 缺少哪一步、如何诚实表达

未完成：五年×三seed入围稳定性；2014一次确认；截至2014的五seed最终拟合；2015-2018冻结批量评分；公司留组压力、配对bootstrap和最终模型工件。完整PLE/TabM、CatBoost/XGBoost等搜索目标也有缺口。

因此GitHub未推送：实验和核验门槛尚未满足，随后仍需现场核验GitHub身份与公开文件隐私。没有上传原始数据、公司级预测或私有源文件。

原文件哈希复核：全部1345个原文件与初始清单一致。 已停止本次训练与临时进程。

面试可说：迁移并核对旧网络，执行了真实的开发期配置与采样控制，发现并纠正迁移错误；尚未完成最终性能验证。不能说已提高历史成绩、完成现代embedding调优或获得五seed公司泛化结论。署名为Qidian (Martin) Xing，原团队按父目录准确致谢；代码与分析由Codex辅助执行。

原8小时预算不可重置。续跑需要新的明确计算授权及单独登记窗口，同时保留此次结果与失败记录。NEXT_ACTIONS.md列出缺项；当前resume命令只作流程说明，不能在过期窗口继续训练。